



AdventureWorks

분석 코드 및 그래프 해설

전처리부터 머신러닝 예측까지: 데이터 사이언스 워크플로우의 이해

주요 분석 단계: 전처리 → EDA → 코호트 → RFM/CLV → 연관 분석 → ML 모델링

분석의 시작: 데이터 전처리 파이프라인

코드 로직: 품질 확보 과정

- 1. 결측치 제거:** 배송일(ShipDateKey)이 없는 불완전한 주문 데이터는 분석 신뢰도를 저해하므로 과감히 삭제합니다.
- 2. 이상치 제거 (IQR 3배):** 평균의 함정에 빠지지 않기 위해, 'Sales Amount' 기준 $3 \times \text{IQR}$ 을 벗어나는 극단적 이상치를 제거하여 모델의 일반화 성능을 높입니다.
- 3. 중복 데이터 정제:** 동일한 주문 라인 키(SalesOrderLineKey)를 가진 중복 행을 제거하여 매출 부풀리기를 방지합니다.

Data Cleaning Pipeline

01_Descriptive_Stats: 데이터의 기초 체력



분포와 왜도 (Skewness)

히스토그램이 오른쪽으로 긴 꼬리를 가진 **양의 왜도**를 보입니다. 이는 소액 주문이 대다수이며, 극소수의 고액 주문이 전체 매출 성격을 결정함을 의미합니다.



변동 계수 (CV%)


평균 대비 표준편차의 비율을 통해 데이터의 산포를 확인합니다. CV가 높을수록 주문당 매출액의 변동성이 커 비즈니스 예측이 어려움을 뜻합니다.



Box Plot의 의미

중앙값과 사분위수를 시각화하여 이상치 유무를 최종 확인합니다. 수염 (Whiskers) 밖의 점들은 여전히 존재할 수 있는 고액 자산가 고객군을 시사합니다.

02_EDA: 이상 징후 감지 및 트렌드



시계열 이동 평균 & 이상치

Bollinger Band 로직: 3개월 이동평균(MA3)에 표준편차의 2배 ($\pm 2\sigma$)를 더하고 뺀 밴드를 설정했습니다.

! **Anomaly (빨간 점):** 밴드를 벗어난 지점은 대량 B2B 계약이나 시스템 오류 가능성을 시사합니다.

📈 **YoY Growth:** 전년 동기 대비 성장률을 텍스트로 표시하여 계절적 성수기를 한눈에 파악하게 합니다.

지역 및 카테고리별 매출 성적표

North America

85% - Market Leader

Europe

45% - Growth Potential

Pacific

25% - Niche Market

"북미 시장의 매출이 타 지역을 압도하고 있으나, 특정 지역 편중 리스크가 존재함을 보여줍니다."

03_Cohort: 고객은 우리를 언제 떠나는가?


코호트 리텐션 히트맵 해설

첫 구매 시점(CohortMonth)을 기준으로 시간 경과에 따른 재구매율을 추적합니다.

- ✓ **대각선 패턴:** 특정 월에 가입한 고객들의 충성도를 비교합니다.
- 📈 **평균 보존 곡선:** 시간이 흐를수록 급격히 하락하는 지점을 찾아 '이탈 방지 캠페인'의 적정 시점을 제안합니다.

[illegible]

04_CRM: 고객 세그먼트 전략



RFM 스코어링 로직

-  **Champions (13점 이상):** 최근에 자주, 많이 산 고객. 특별 관리 대상.
-  **Loyal (10-12점):** 꾸준히 관계를 맺고 있는 핵심 지지층.
-  **At Risk (7-9점):** 한때 VIP였으나 최근 활동이 뜸해진 고객. 이탈 경보!
-  **Lost (7점 미만):** 오랫동안 활동이 없는 휴면 고객.

Customer Lifetime Value (고객 생애 가치)

평균 CLV 예측 (12개월)

\$2,450

Champions 가치

\$15,800

CLV 산출 공식 (Simple Model)

$CLV = (\text{평균 주문액}) \times (\text{월평균 구매 빈도}) \times (\text{예측 기간: 12개월})$

*이 수치는 마케팅 비용(CAC)을 얼마나 집행할 수 있는지 결정하는 핵심 지표입니다.

이탈 위험군 분석 및 대응

-  **Recency 기반 위험 분류:** 마지막 구매일로부터 180일 이상 경과한 고객을 High Risk로 분류했습니다.
-  **위험군별 매출 기여도:** 이탈 위험군이 과거에 얼마나 많은 매출을 기여했는지 파악하여, '가치 있는 고객'부터 우선적으로 복귀 프로모션을 제안합니다.
-  **선제적 대응:** Churn Risk가 'Medium'에서 'High'로 넘어가기 직전의 고객군에 개인화된 할인 쿠폰을 발송하는 전략이 유효합니다.

05_Market Basket: 장바구니 연관 분석



공동 구매 행렬

Heatmap에서 색이 짙을수록 'Bikes'와 'Accessories'를 함께 구매하는 경향이 강함을 뜻합니다.



카테고리 번들링

주요 조합(Pair)을 확인하여 웹사이트의 '함께 사면 좋은 상품' 추천 알고리즘의 기초 데이터로 활용합니다.



크로스셀링 기회

특정 카테고리 구매 시 사은품 증정이나 패키지 상품 구성을 통한 객단가(AOV) 상승 전략을 도출합니다.

 Market Basket Diagram

07~08: AI 예측 모델

Random Forest 모델링

1. 분류(Classification): RFM 지표를 바탕으로 고객이 다음에 어떤 카테고리를 살지 예측합니다.

2. 회귀(Regression): 시계열 교차 검증(TimeSeriesCV)을 통해 미래 월별 판매량을 예측합니다.

특성 중요도 (Feature Importance): 분류와 회귀 모델에서 어떤 피처가 예측에 큰 기여를 하는지 변수 중요도를 확인했습니다.






Image Sources



<https://www.couchbase.com/wp-content/uploads/sites/5/2026/05/image1-1-1024x816-1.png>

Source: www.couchbase.com




https://miro.medium.com/v2/resize:fit:1200/1*yeLT55Hn7s22Jujox90GDg.png

Source: medium.com




https://miro.medium.com/v2/resize:fit:1400/0*cJ-X4dfIEpu38TjH

Source: medium.com




<https://towardsdatascience.com/wp-content/uploads/2020/08/1Seczqf9R0suiKlmsN3vRRA.png>

Source: towardsdatascience.com



<https://upload.wikimedia.org/wikipedia/commons/4/4a/AffinityAnalysis.png>

Source: en.wikipedia.org



https://mljar.com/blog/visualize-sklearn-tree/sklearn_plot_regression.png

Source: mljar.com